

# Cadenas de Markov

IIC3810

Marcelo Arenas, Luis Alberto Croquevielle y Thomas  
Reisenegger

# Motivación: una pregunta pendiente del capítulo anterior

¿Cómo podemos construir un generador (casi) uniforme para una relación?

# Motivación: una pregunta pendiente del capítulo anterior

¿Cómo podemos construir un generador (casi) uniforme para una relación?

Recuerde el problema KS definido en el capítulo anterior y la relación:

$$R_{KS} = \{((\vec{a}, b), \vec{x}) \mid \vec{a} \in \mathbb{N}^n, b \in \mathbb{Z}, \vec{x} \in \{0, 1\}^n \text{ para } n \geq 1, \text{ y } \vec{a} \cdot \vec{x} \leq b\}$$

# Motivación: una pregunta pendiente del capítulo anterior

¿Cómo podemos construir un generador (casi) uniforme para una relación?

Recuerde el problema KS definido en el capítulo anterior y la relación:

$$R_{KS} = \{((\vec{a}, b), \vec{x}) \mid \vec{a} \in \mathbb{N}^n, b \in \mathbb{Z}, \vec{x} \in \{0, 1\}^n \text{ para } n \geq 1, \text{ y } \vec{a} \cdot \vec{x} \leq b\}$$

Vamos a responder primero una pregunta más específica: ¿Cómo podemos construir un generador (casi) uniforme para  $R_{KS}$ ?

- ▶ La respuesta a esta pregunta va a tener los ingredientes necesarios para responder la pregunta más general

# Una secuencia de variables aleatorias para generar $R_{KS}$

Fije  $n \geq 1$ ,  $\vec{a} \in \mathbb{N}^n$  y  $b \in \mathbb{N}$

- ▶ Y suponga que  $\Omega = \{\vec{x} \in \{0, 1\}^n \mid \vec{a} \cdot \vec{x} \leq b\}$

Nótese que  $\Omega \neq \emptyset$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Fije  $n \geq 1$ ,  $\vec{a} \in \mathbb{N}^n$  y  $b \in \mathbb{N}$

- ▶ Y suponga que  $\Omega = \{\vec{x} \in \{0, 1\}^n \mid \vec{a} \cdot \vec{x} \leq b\}$

Nótese que  $\Omega \neq \emptyset$

Considere una secuencia  $\{X_t\}_{t \in \mathbb{N}}$  de variables aleatorias con recorrido  $\Omega$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Fije  $n \geq 1$ ,  $\vec{a} \in \mathbb{N}^n$  y  $b \in \mathbb{N}$

- ▶ Y suponga que  $\Omega = \{\vec{x} \in \{0, 1\}^n \mid \vec{a} \cdot \vec{x} \leq b\}$

Nótese que  $\Omega \neq \emptyset$

Considere una secuencia  $\{X_t\}_{t \in \mathbb{N}}$  de variables aleatorias con recorrido  $\Omega$

- ▶ El dominio de cada variable  $X_t$  es  $D_t$ , el cual no necesitamos definir

# Una secuencia de variables aleatorias para generar $R_{KS}$

Fije  $n \geq 1$ ,  $\vec{a} \in \mathbb{N}^n$  y  $b \in \mathbb{N}$

- Y suponga que  $\Omega = \{\vec{x} \in \{0, 1\}^n \mid \vec{a} \cdot \vec{x} \leq b\}$

Nótese que  $\Omega \neq \emptyset$

Considere una secuencia  $\{X_t\}_{t \in \mathbb{N}}$  de variables aleatorias con recorrido  $\Omega$

- El dominio de cada variable  $X_t$  es  $D_t$ , el cual no necesitamos definir

Decimos que  $\Omega$  es el conjunto de estados de la secuencia  $\{X_t\}_{t \in \mathbb{N}}$



# Una secuencia de variables aleatorias para generar $R_{KS}$

Dado  $t \in \mathbb{N}$  y  $\vec{x} \in \Omega$ , nos interesa calcular  $\Pr(X_t = \vec{x})$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Dado  $t \in \mathbb{N}$  y  $\vec{x} \in \Omega$ , nos interesa calcular  $\Pr(X_t = \vec{x})$

Para calcular esta probabilidad necesitamos definir la dinámica de la secuencia

- ▶ Vale decir, necesitamos definir cómo se cambio de estado al pasar de tiempo  $t$  a tiempo  $t + 1$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Dado  $t \in \mathbb{N}$  y  $\vec{x} \in \Omega$ , nos interesa calcular  $\Pr(X_t = \vec{x})$

Para calcular esta probabilidad necesitamos definir la dinámica de la secuencia

- ▶ Vale decir, necesitamos definir cómo se cambio de estado al pasar de tiempo  $t$  a tiempo  $t + 1$

De manera formal, dado  $t \in \mathbb{N}$  y  $\vec{x}, \vec{y} \in \Omega$ , necesitamos definir:

$$\Pr(X_{t+1} = \vec{y} \mid X_t = \vec{x})$$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Suponga que en tiempo  $t$  estamos en el estado  $\vec{x} = (x_1, \dots, x_n)$

# Una secuencia de variables aleatorias para generar $R_{KS}$

Suponga que en tiempo  $t$  estamos en el estado  $\vec{x} = (x_1, \dots, x_n)$

El estado  $\vec{y}$  en el tiempo  $t + 1$  se obtiene utilizando el siguiente procedimiento:

## **GenerarSiguiente( $\vec{x}$ )**

Escoja  $c \in \{0, 1\}$  con distribución uniforme

**if**  $c = 0$  **then return**  $\vec{x}$

**else**

Escoja  $i \in \{1, \dots, n\}$  con distribución uniforme

$\vec{u} := (x_1, \dots, x_{i-1}, 1 - x_i, x_{i+1}, \dots, x_n)$

**if**  $\vec{a} \cdot \vec{u} \leq b$  **then return**  $\vec{u}$

**else return**  $\vec{x}$

Tenemos entonces que  $\vec{y} = \text{GenerarSiguiente}(\vec{x})$

## Ejercicios

Sea  $t \in \mathbb{N}$

1. Dados  $\vec{x}, \vec{y} \in \Omega$ , calcule  $\Pr(X_{t+1} = \vec{y} \mid X_t = \vec{x})$ 
  - Considere de manera separada los casos  $\vec{x} \neq \vec{y}$  y  $\vec{x} = \vec{y}$

2. Demuestre que para todo  $\vec{x}, \vec{y} \in \Omega$ , existe  $t' > t$  tal que:

$$\Pr(X_{t'} = \vec{y} \mid X_t = \vec{x}) > 0$$

3. Dados  $\vec{x}_0, \vec{x}_1, \dots, \vec{x}_t, \vec{x}_{t+1} \in \Omega$ , demuestre que:

$$\Pr(X_{t+1} = \vec{x}_{t+1} \mid X_0 = \vec{x}_0 \wedge X_1 = \vec{x}_1 \wedge \dots \wedge X_t = \vec{x}_t) = \Pr(X_{t+1} = \vec{x}_{t+1} \mid X_t = \vec{x}_t)$$

# ¿A qué converge la secuencia?

Sea  $\vec{x}$  un vector arbitrario en  $\Omega$

Suponga que en tiempo 0 estamos en el estado  $\vec{x}$ , y que en cada instante cambiamos de estado utilizando el procedimiento **GenerarSiguiente**

# ¿A qué converge la secuencia?

Sea  $\vec{x}$  un vector arbitrario en  $\Omega$

Suponga que en tiempo 0 estamos en el estado  $\vec{x}$ , y que en cada instante cambiamos de estado utilizando el procedimiento **GenerarSiguiente**

- ▶ ¿Cuáles son los estados a los que podríamos llegar en un tiempo  $t \gg 0$ ?
- ▶ ¿Cuál es la probabilidad de estar en un estado específico en este tiempo  $t$ ?



# ¿A qué converge la secuencia?

Sea  $\vec{x}$  un vector arbitrario en  $\Omega$

Suponga que en tiempo 0 estamos en el estado  $\vec{x}$ , y que en cada instante cambiamos de estado utilizando el procedimiento **GenerarSiguiente**

- ▶ ¿Cuáles son los estados a los que podríamos llegar en un tiempo  $t \gg 0$ ?
- ▶ ¿Cuál es la probabilidad de estar en un estado específico en este tiempo  $t$ ?
- ▶ ¿Es posible llegar a una distribución estacionaria, vale decir, un tiempo  $t'$  tal que para todo  $\vec{y} \in \Omega$  se tiene que  $\mathbf{Pr}(X_{t'+1} = \vec{y}) = \mathbf{Pr}(X_{t'} = \vec{y})$ ?

# ¿A qué converge la secuencia?

Sea  $\vec{x}$  un vector arbitrario en  $\Omega$

Suponga que en tiempo 0 estamos en el estado  $\vec{x}$ , y que en cada instante cambiamos de estado utilizando el procedimiento **GenerarSiguiente**

- ▶ ¿Cuáles son los estados a los que podríamos llegar en un tiempo  $t \gg 0$ ?  
¿Cuál es la probabilidad de estar en un estado específico en este tiempo  $t$ ?
- ▶ ¿Es posible llegar a una distribución estacionaria, vale decir, un tiempo  $t'$  tal que para todo  $\vec{y} \in \Omega$  se tiene que  $\mathbf{Pr}(X_{t'+1} = \vec{y}) = \mathbf{Pr}(X_{t'} = \vec{y})$ ?
- ▶ ¿Existe una única distribución estacionaria?

# ¿A qué converge la secuencia?

Sea  $\vec{x}$  un vector arbitrario en  $\Omega$

Suponga que en tiempo 0 estamos en el estado  $\vec{x}$ , y que en cada instante cambiamos de estado utilizando el procedimiento **GenerarSiguiente**

- ▶ ¿Cuáles son los estados a los que podríamos llegar en un tiempo  $t \gg 0$ ?  
¿Cuál es la probabilidad de estar en un estado específico en este tiempo  $t$ ?
- ▶ ¿Es posible llegar a una distribución estacionaria, vale decir, un tiempo  $t'$  tal que para todo  $\vec{y} \in \Omega$  se tiene que  $\mathbf{Pr}(X_{t'+1} = \vec{y}) = \mathbf{Pr}(X_{t'} = \vec{y})$ ?
- ▶ ¿Existe una única distribución estacionaria?

¿Cuáles son las respuestas a las preguntas anteriores si cambiamos  $\vec{x}$  por otro vector inicial?

# La secuencia converge a la distribución uniforme

## Ejercicios

1. Dado  $t \in \mathbb{N}$  y  $\vec{x} \in \Omega$ , demuestre que:

$$\sum_{\vec{y} \in \Omega} \mathbf{Pr}(X_{t+1} = \vec{y} \mid X_t = \vec{x}) = 1$$

$$\sum_{\vec{y} \in \Omega} \mathbf{Pr}(X_{t+1} = \vec{x} \mid X_t = \vec{y}) = 1$$

2. Demuestre que la distribución uniforme es una distribución estacionaria.

- Vale decir, demuestre que si para  $t \in \mathbb{N}$  se tiene que  $\mathbf{Pr}(X_t = \vec{x}) = \frac{1}{|\Omega|}$  para cada  $\vec{x} \in \Omega$ , entonces:

$$\mathbf{Pr}(X_{t+1} = \vec{y}) = \mathbf{Pr}(X_t = \vec{y}) \text{ para cada } \vec{y} \in \Omega$$

# Generando $R_{KS}$ con distribución (casi) uniforme

Para generar los elementos de  $\Omega$  con distribución (casi) uniforme utilizamos el siguiente procedimiento:

```
Sea  $\vec{x}$  un elemento arbitrario de  $\Omega$   
 $t = f(|\vec{a}| + |b|)$   
for  $i := 1$  to  $t$  do  
     $\vec{x} := \mathbf{GenerarSiguiete}(\vec{x})$   
return  $\vec{x}$ 
```

Donde  $|\vec{a}| + |b|$  es el tamaño de la entrada  $(\vec{a}, b)$

# Generando $R_{KS}$ con distribución (casi) uniforme

Para generar los elementos de  $\Omega$  con distribución (casi) uniforme utilizamos el siguiente procedimiento:

```
Sea  $\vec{x}$  un elemento arbitrario de  $\Omega$   
 $t = f(|\vec{a}| + |b|)$   
for  $i := 1$  to  $t$  do  
     $\vec{x} := \mathbf{GenerarSiguiete}(\vec{x})$   
return  $\vec{x}$ 
```

Donde  $|\vec{a}| + |b|$  es el tamaño de la entrada  $(\vec{a}, b)$

¿Qué condiciones deben cumplirse para que este procedimiento genere  $\Omega$  con distribución (casi) uniforme y en tiempo polinomial?

# Las condiciones para la generación (casi) uniforme

- ▶ La secuencia debe converger a la distribución uniforme desde cualquier punto de partida  $\vec{x} \in \Omega$

# Las condiciones para la generación (casi) uniforme

- ▶ La secuencia debe converger a la distribución uniforme desde cualquier punto de partida  $\vec{x} \in \Omega$
- ▶ La distribución uniforme debe ser la única distribución a la que converge la secuencia



# Las condiciones para la generación (casi) uniforme

- ▶ La secuencia debe converger a la distribución uniforme desde cualquier punto de partida  $\vec{x} \in \Omega$
- ▶ La distribución uniforme debe ser la única distribución a la que converge la secuencia
- ▶  $f(n)$  debe estar acotada superiormente por un polinomio

# Las condiciones para la generación (casi) uniforme

- ▶ Debe ser posible calcular **GenerarSiguiente**( $\vec{x}$ ) en tiempo polinomial

# Las condiciones para la generación (casi) uniforme

- ▶ Debe ser posible calcular **GenerarSiguiente**( $\vec{x}$ ) en tiempo polinomial
- ▶ Después de ejecutar  $t$  pasos se debe tener una garantía de que estamos cerca de la distribución uniforme
  - ▶ Obtenemos entonces un generador casi uniforme para los elementos de  $\Omega$

# Las condiciones para la generación (casi) uniforme

- ▶ Debe ser posible calcular **GenerarSiguiente**( $\vec{x}$ ) en tiempo polinomial
- ▶ Después de ejecutar  $t$  pasos se debe tener una garantía de que estamos cerca de la distribución uniforme
  - ▶ Obtenemos entonces un generador casi uniforme para los elementos de  $\Omega$

Todas estas condiciones han sido estudiadas para las cadenas de Markov.

- ▶ Vamos a introducir y estudiar esta herramienta esencial para el muestreo de variables aleatorias

# Las cadenas de Markov

Considere una sucesión  $\{X_t\}_{t \in \mathbb{N}}$  de variables aleatorias.

# Las cadenas de Markov

Considere una sucesión  $\{X_t\}_{t \in \mathbb{N}}$  de variables aleatorias.

## Definición

$\{X_t\}_{t \in \mathbb{N}}$  es una cadena de Markov con conjunto de estados  $\Omega$  si:

1.  $\Omega$  es un conjunto finito o infinito enumerable, y  $X_t : D_t \rightarrow \Omega$  para cada  $t \in \mathbb{N}$
2. Existe  $p : \Omega \times \Omega \rightarrow [0, 1]$  tal que para cada  $t \in \mathbb{N}$  y cada secuencia  $a_0, \dots, a_t, a_{t+1}$  de elementos de  $\Omega$ :

$$\Pr(X_{t+1} = a_{t+1} \mid X_t = a_t \wedge \dots \wedge X_0 = a_0) =$$

$$\Pr(X_{t+1} = a_{t+1} \mid X_t = a_t) = p(a_{t+1}, a_t)$$

# Las cadenas de Markov

En una cadena de Markov la distribución de probabilidades en el tiempo  $t + 1$  sólo depende de la distribución de probabilidades en el tiempo  $t$

- ▶ Consideramos cadenas discretas: el tiempo es un conjunto infinito enumerable, y el conjunto de estados  $\Omega$  es finito o infinito enumerable

# Las cadenas de Markov

En una cadena de Markov la distribución de probabilidades en el tiempo  $t + 1$  sólo depende de la distribución de probabilidades en el tiempo  $t$

- ▶ Consideramos cadenas discretas: el tiempo es un conjunto infinito enumerable, y el conjunto de estados  $\Omega$  es finito o infinito enumerable

Además, consideramos cadenas de Markov donde las probabilidades de transición no dependen del tiempo.

- ▶ Para cada  $t_1, t_2 \in \mathbb{N}$  y  $a, b \in \Omega$ :

$$\Pr(X_{t_1+1} = a \mid X_{t_1} = b) = \Pr(X_{t_2+1} = a \mid X_{t_2} = b)$$



# Las cadenas de Markov

En una cadena de Markov la distribución de probabilidades en el tiempo  $t + 1$  sólo depende de la distribución de probabilidades en el tiempo  $t$

- ▶ Consideramos cadenas discretas: el tiempo es un conjunto infinito enumerable, y el conjunto de estados  $\Omega$  es finito o infinito enumerable

Además, consideramos cadenas de Markov donde las probabilidades de transición no dependen del tiempo.

- ▶ Para cada  $t_1, t_2 \in \mathbb{N}$  y  $a, b \in \Omega$ :

$$\Pr(X_{t_1+1} = a \mid X_{t_1} = b) = \Pr(X_{t_2+1} = a \mid X_{t_2} = b)$$

Estos son llamadas cadenas de Markov homogéneas.

# Las cadenas de Markov

En una cadena de Markov la distribución de probabilidades en el tiempo  $t + 1$  sólo depende de la distribución de probabilidades en el tiempo  $t$

- ▶ Consideramos cadenas discretas: el tiempo es un conjunto infinito enumerable, y el conjunto de estados  $\Omega$  es finito o infinito enumerable

Además, consideramos cadenas de Markov donde las probabilidades de transición no dependen del tiempo.

- ▶ Para cada  $t_1, t_2 \in \mathbb{N}$  y  $a, b \in \Omega$ :

$$\Pr(X_{t_1+1} = a \mid X_{t_1} = b) = \Pr(X_{t_2+1} = a \mid X_{t_2} = b)$$

Estos son llamadas cadenas de Markov homogéneas.

En general, consideramos cadenas de Markov con conjuntos finitos de estados.

# Representando una cadena de Markov

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov con conjunto de estados  $\Omega$

- ▶ Suponemos además que  $p : \Omega \times \Omega \rightarrow [0, 1]$  es la función que define las probabilidades de transición.

# Representando una cadena de Markov

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov con conjunto de estados  $\Omega$

- ▶ Suponemos además que  $p : \Omega \times \Omega \rightarrow [0, 1]$  es la función que define las probabilidades de transición.

Podemos representar cada variable aleatoria  $X_t$  como un vector  $\vec{x}_t$  tal que:

$$\text{para cada } a \in \Omega \text{ se tiene que } \vec{x}_t[a] = \mathbf{Pr}(X_t = a)$$

# Representando una cadena de Markov

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov con conjunto de estados  $\Omega$

- Suponemos además que  $p : \Omega \times \Omega \rightarrow [0, 1]$  es la función que define las probabilidades de transición.

Podemos representar cada variable aleatoria  $X_t$  como un vector  $\vec{x}_t$  tal que:

$$\text{para cada } a \in \Omega \text{ se tiene que } \vec{x}_t[a] = \mathbf{Pr}(X_t = a)$$

Además, podemos representar la cadena de Markov como una matriz  $P$  de  $|\Omega| \times |\Omega|$ :

$$\text{para cada } a, b \in \Omega, \text{ se tiene que } P[a, b] = p(a, b)$$

$P$  es llamada la matriz de transición de la cadena de Markov.

# Representando una cadena de Markov

Dado  $a \in \Omega$  y  $t \in \mathbb{N}$ , tenemos que:

$$\begin{aligned}\mathbf{Pr}(X_{t+1} = a) &= \sum_{b \in \Omega} \mathbf{Pr}(X_{t+1} = a \mid X_t = b) \cdot \mathbf{Pr}(X_t = b) = \\ &\sum_{b \in \Omega} p(a, b) \cdot \mathbf{Pr}(X_t = b) = \sum_{b \in \Omega} P[a, b] \cdot \mathbf{Pr}(X_t = b)\end{aligned}$$

# Representando una cadena de Markov

Dado  $a \in \Omega$  y  $t \in \mathbb{N}$ , tenemos que:

$$\begin{aligned}\mathbf{Pr}(X_{t+1} = a) &= \sum_{b \in \Omega} \mathbf{Pr}(X_{t+1} = a \mid X_t = b) \cdot \mathbf{Pr}(X_t = b) = \\ &\sum_{b \in \Omega} p(a, b) \cdot \mathbf{Pr}(X_t = b) = \sum_{b \in \Omega} P[a, b] \cdot \mathbf{Pr}(X_t = b)\end{aligned}$$

Dado que  $\vec{x}_{t+1}[a] = \mathbf{Pr}(X_{t+1} = a)$  y  $\vec{x}_t[b] = \mathbf{Pr}(X_t = b)$  para cada  $a, b \in \Omega$  y  $t \in \mathbb{N}$ , concluimos que:

$$P\vec{x}_t = \vec{x}_{t+1}$$

## Ejercicios

Sea  $P$  la matriz de transición de una cadena de Markov.

1. Demuestre que para cada columna de  $P$ , se tiene que la suma de sus valores es 1
2. Para cada fila de  $P$ , ¿se debe tener que la suma de sus valores es 1?
  - ¿Era cierta esta propiedad para la matriz  $P$  de la cadena de Markov para  $R_{KS}$ ?




# Una cadena de Markov como un grafo

La matriz de transición  $P$  de una cadena de Markov con conjunto de estados  $\Omega$  puede ser vista como un grafo  $G_P$  con pesos:

- ▶  $\Omega$  es el conjunto de nodos de  $G_P$
- ▶ Dados  $a, b \in \Omega$ , el peso del arco  $(a, b)$  en  $G$  es  $P[b, a]$ 
  - ▶ Vale decir, el peso de  $(a, b)$  representa la probabilidad de pasar al estado  $b$  dado que estábamos en el estado  $a$

# Una cadena de Markov como un grafo: un ejemplo

$$\Omega = \{1, 2, 3, 4\} \quad P = \begin{pmatrix} 0.2 & 0 & 0.6 & 0.9 \\ 0.3 & 1 & 0 & 0 \\ 0.4 & 0 & 0.2 & 0 \\ 0.1 & 0 & 0.2 & 0.1 \end{pmatrix}$$



# Algunas propiedades de las cadenas de Markov

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov con conjunto de estados  $\Omega$  y matriz de transición  $P$

- ▶ Además, defina  $P^0$  como la matriz identidad y  $P^{t+1} = PP^t$  para todo  $t \in \mathbb{N}$

# Algunas propiedades de las cadenas de Markov

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov con conjunto de estados  $\Omega$  y matriz de transición  $P$

- ▶ Además, defina  $P^0$  como la matriz identidad y  $P^{t+1} = PP^t$  para todo  $t \in \mathbb{N}$

## Ejercicios

1. Demuestre que para cada  $t \in \mathbb{N}$  y  $a, b \in \Omega$  se tiene que:

$$\Pr(X_t = a \mid X_0 = b) = P^t[a, b]$$

2. Demuestre para cada  $t_1, t_2 \in \mathbb{N}$  y  $a, b \in \Omega$  se tiene que:

$$\Pr(X_{t_1+t_2} = a \mid X_{t_1} = b) = \Pr(X_{t_2} = a \mid X_0 = b)$$

# La demostración de la existencia del límite

Para cada  $k \geq 1$ , tenemos que:

$$\begin{aligned}M_a^{(k \cdot n_0 + n)} - m_a^{(k \cdot n_0 + n)} &= M_a^{(n_0 + (k-1) \cdot n_0 + n)} - m_a^{(n_0 + (k-1) \cdot n_0 + n)} \\&\leq (1 - \ell \cdot t) \cdot (M_a^{((k-1) \cdot n_0 + n)} - m_a^{((k-1) \cdot n_0 + n)}) \\&= (1 - \ell \cdot t) \cdot (M_a^{(n_0 + (k-2) \cdot n_0 + n)} - m_a^{(n_0 + (k-2) \cdot n_0 + n)}) \\&\leq (1 - \ell \cdot t)^2 \cdot (M_a^{((k-2) \cdot n_0 + n)} - m_a^{((k-2) \cdot n_0 + n)}) \\&\leq \dots \\&\leq (1 - \ell \cdot t)^k \cdot (M_a^{(n)} - m_a^{(n)})\end{aligned}$$

Notése que la desigualdad también es válida para  $k = 0$

# La demostración de la existencia del límite

Considerando  $n = 0$ , obtenemos la sub-sucesión  $(M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)})_{k \in \mathbb{N}}$  de la sucesión  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$

Dado que  $0 \leq (1 - \ell \cdot t) < 1$  (ya que  $t, \ell > 0$ ), para esta sub-sucesión se tiene que:

$$0 \leq \lim_{k \rightarrow \infty} (M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)}) \leq \lim_{k \rightarrow \infty} (1 - \ell \cdot t)^k \cdot (M_c^{(n)} - m_c^{(n)}) = 0$$

Vale decir,

$$\lim_{k \rightarrow \infty} (M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)}) = 0$$

# La demostración de la existencia del límite

Para todo  $n \in \mathbb{N}$  se tiene que:

- ▶  $m_a^{(n)} \leq m_a^{(n+1)}$
- ▶  $M_a^{(n)} \geq M_a^{(n+1)}$
- ▶  $m_a^{(n)} \leq M_a^{(n)}$

Por lo tanto, para todo  $n \in \mathbb{N}$  se tiene que:

- ▶  $M_a^{(n)} - m_a^{(n)} \geq 0$
- ▶  $M_a^{(n+1)} - m_a^{(n+1)} \leq M_a^{(n)} - m_a^{(n)}$

# La demostración de la existencia del límite

Dado que  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  es una sucesión de números reales monótona decreciente y acotada inferiormente, concluimos que existe  $u \in \mathbb{R}$  tal que:

$$\lim_{n \rightarrow \infty} (M_a^{(n)} - m_a^{(n)}) = u$$



# La demostración de la existencia del límite

Dado que  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  es una sucesión de números reales monótona decreciente y acotada inferiormente, concluimos que existe  $u \in \mathbb{R}$  tal que:

$$\lim_{n \rightarrow \infty} (M_a^{(n)} - m_a^{(n)}) = u$$

Además, para la sub-sucesión  $(M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)})_{k \in \mathbb{N}}$  de  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  se cumple que:

$$\lim_{k \rightarrow \infty} (M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)}) = 0$$

# La demostración de la existencia del límite

Dado que  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  es una sucesión de números reales monótona decreciente y acotada inferiormente, concluimos que existe  $u \in \mathbb{R}$  tal que:

$$\lim_{n \rightarrow \infty} (M_a^{(n)} - m_a^{(n)}) = u$$

Además, para la sub-sucesión  $(M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)})_{k \in \mathbb{N}}$  de  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  se cumple que:

$$\lim_{k \rightarrow \infty} (M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)}) = 0$$

¡Concluimos que  $u = 0$ !

# La demostración de la existencia del límite

Dado que  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  es una sucesión de números reales monótona decreciente y acotada inferiormente, concluimos que existe  $u \in \mathbb{R}$  tal que:

$$\lim_{n \rightarrow \infty} (M_a^{(n)} - m_a^{(n)}) = u$$

Además, para la sub-sucesión  $(M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)})_{k \in \mathbb{N}}$  de  $(M_a^{(n)} - m_a^{(n)})_{n \in \mathbb{N}}$  se cumple que:

$$\lim_{k \rightarrow \infty} (M_a^{(k \cdot n_0)} - m_a^{(k \cdot n_0)}) = 0$$

¡Concluimos que  $u = 0$ !

- ▶ ¿Cómo se demuestra que las dos sucesiones tienen el mismo límite? ¿Por qué es importante aquí que  $n_0 \geq 1$ ? □

# Irreducibilidad, aperiodicidad y el caso infinito

Irreducibilidad y aperiodicidad **no** son condiciones suficientes para asegurar que una cadena de Markov con un conjunto infinito (enumerable) de estados tiene una distribución estacionaria única.

- ▶ De hecho, bajo estas condiciones ni siquiera se puede asegurar que la cadena tiene una distribución estacionaria

# Irreducibilidad, aperiodicidad y el caso infinito

Irreducibilidad y aperiodicidad **no** son condiciones suficientes para asegurar que una cadena de Markov con un conjunto infinito (enumerable) de estados tiene una distribución estacionaria única.


- ▶ De hecho, bajo estas condiciones ni siquiera se puede asegurar que la cadena tiene una distribución estacionaria

## Ejercicio

Construya una cadena de Markov irreducible, aperiódica, con un conjunto infinito de estados y que no tenga distribución estacionaria.

# Una solución al ejercicio

Considere la siguiente cadena de Markov con conjunto de estado  $\Omega = \mathbb{N}$ :



Esta cadena de Markov es irreducible y aperiódica.

- ▶ Es fácil ver que el estado 0 es aperiódico, de lo cual se concluye que la cadena de Markov es aperiódica dado que es irreducible

# Una solución al ejercicio

Suponga que  $P$  es la matriz de transición de la cadena de Markov, y  $\vec{\lambda}$  es una distribución estacionaria para ella, vale decir,

$$P\vec{\lambda} = \vec{\lambda}$$

Además, suponga que  $\vec{\lambda}[i] = \lambda_i$  para cada  $i \in \mathbb{N}$

- Tenemos que  $\sum_{i \in \mathbb{N}} \lambda_i = 1$

# Una solución al ejercicio

Considerando las definiciones de  $P$  y  $\vec{\lambda}$  obtenemos:

$$\lambda_0 = \frac{1}{4} \cdot \lambda_0 + \frac{1}{4} \cdot \lambda_1$$

Por lo tanto:  $3 \cdot \lambda_0 = \lambda_1$



# Una solución al ejercicio

Considere  $i > 0$  y suponga que  $3 \cdot \lambda_{i-1} = \lambda_i$

Tenemos que:

$$\begin{aligned}\lambda_i &= \frac{3}{4} \cdot \lambda_{i-1} + \frac{1}{4} \cdot \lambda_{i+1} \\ &= \frac{3}{4} \cdot \frac{1}{3} \cdot \lambda_i + \frac{1}{4} \cdot \lambda_{i+1} \\ &= \frac{1}{4} \cdot \lambda_i + \frac{1}{4} \cdot \lambda_{i+1}\end{aligned}$$

Por lo tanto:  $3 \cdot \lambda_i = \lambda_{i+1}$

# Una solución al ejercicio

Concluimos que  $\lambda_i = 3^i \cdot \lambda_0$  para cada  $i \in \mathbb{N}$

# Una solución al ejercicio

Concluimos que  $\lambda_i = 3^i \cdot \lambda_0$  para cada  $i \in \mathbb{N}$

Así, dado que  $\lambda_i \leq 1$  para cada  $i \in \mathbb{N}$ , se debe tener que  $\lambda_0 = 0$

# Una solución al ejercicio

Concluimos que  $\lambda_i = 3^i \cdot \lambda_0$  para cada  $i \in \mathbb{N}$

Así, dado que  $\lambda_i \leq 1$  para cada  $i \in \mathbb{N}$ , se debe tener que  $\lambda_0 = 0$

Concluimos entonces que  $\lambda_i = 0$  para cada  $i \in \mathbb{N}$ , lo cual contradice la condición  $\sum_{i \in \mathbb{N}} \lambda_i = 1$

- ▶ No podemos entonces tener una distribución estacionaria para  $P$   $\square$

# ¿Cómo podemos asegurar convergencia en el caso infinito?

Vamos a ver que irreducibilidad y aperiodicidad sí son condiciones útiles en el caso infinito, pero cuando con consideradas junto con una tercera propiedad fundamental.

# La noción de estado recurrente

Sea  $b$  un estado en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$

# La noción de estado recurrente

Sea  $b$  un estado en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$

Definimos  $T_b$  como una variable aleatoria que registra el primer instante de tiempo mayor a 0 en que llegamos a  $b$ , suponiendo que en el tiempo 0 estábamos en  $b$

- ▶ Vale decir, si el valor de  $T_b$  es  $n$ , con  $n \geq 1$ , entonces  $X_0 = b$ ,  $X_1 \neq b$ , ...,  $X_{n-1} \neq b$  y  $X_n = b$

Este tiempo de retorno a  $b$  es llamado *hitting time*

# La noción de estado recurrente

Sea  $b$  un estado en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$

Definimos  $T_b$  como una variable aleatoria que registra el primer instante de tiempo mayor a 0 en que llegamos a  $b$ , suponiendo que en el tiempo 0 estábamos en  $b$

- ▶ Vale decir, si el valor de  $T_b$  es  $n$ , con  $n \geq 1$ , entonces  $X_0 = b$ ,  $X_1 \neq b$ , ...,  $X_{n-1} \neq b$  y  $X_n = b$

Este tiempo de retorno a  $b$  es llamado *hitting time*

## Definición

$b$  es recurrente si  $\sum_{n \geq 1} \Pr(T_b = n) = 1$ , y  $b$  es transitorio en caso contrario.



# Una caracterización de los estado recurrentes

Sea  $b$  un estado en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$

Defina:

$$p_b = \sum_{n \geq 1} \mathbf{Pr}(T_b = n)$$

# Una caracterización de los estado recurrentes

Sea  $b$  un estado en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$

Defina:

$$p_b = \sum_{n \geq 1} \mathbf{Pr}(T_b = n)$$

## Ejercicio

Demuestre que  $p_b \in [0, 1]$

- ▶ Nótese que no estamos asumiendo que  $b$  es recurrente
- ▶ ¿Es posible tener una cadena de Markov donde  $p_b = 0$ ?

# Una caracterización de los estado recurrentes

Suponga que la matriz de transición de  $\{X_t\}_{t \in \mathbb{N}}$  es  $P$ , y recuerde que  $G_P$  es grafo que representa a  $P$

Partiendo desde el estado  $b$ , consideramos caminatas sobre  $G_P$  que sólo utilizan arcos con probabilidad mayor a cero y tiene largo infinito.

- ▶ Podemos realizar estas caminatas incluso si  $\{X_t\}_{t \in \mathbb{N}}$  tiene un conjunto finito de estados

Defina una variable aleatoria  $V_b$  que cuenta el número total de veces que  $b$  es visitado en las caminatas.

- ▶ El punto de partida  $b$  es considerado como la primera visita a este estado

# Una caracterización de los estado recurrentes

Dado un número natural  $n \geq 1$ , tenemos que:

$$\Pr(V_b = n) = p_b^{n-1} \cdot (1 - p_b)$$

# Una caracterización de los estado recurrentes

Dado un número natural  $n \geq 1$ , tenemos que:

$$\Pr(V_b = n) = p_b^{n-1} \cdot (1 - p_b)$$

## Proposición

*b es recurrente si y sólo si  $\mathbf{E}[V_b] = \infty$*

# Una caracterización de los estado recurrentes

Dado un número natural  $n \geq 1$ , tenemos que:

$$\Pr(V_b = n) = p_b^{n-1} \cdot (1 - p_b)$$

## Proposición

*$b$  es recurrente si y sólo si  $\mathbf{E}[V_b] = \infty$*

## Ejercicio

Demuestre la proposición.

# Una caracterización de los estado recurrentes

Dado un número natural  $n \geq 1$ , tenemos que:

$$\Pr(V_b = n) = p_b^{n-1} \cdot (1 - p_b)$$

## Proposición

$b$  es recurrente si y sólo si  $\mathbf{E}[V_b] = \infty$

## Ejercicio

Demuestre la proposición.

¡Tenemos entonces que  $b$  es recurrente si y sólo si  $b$  es visitado una cantidad infinita de veces!

# Una segunda caracterización de los estado recurrentes

Partiendo desde el estado  $b$ , nuevamente consideramos caminatas sobre  $G_P$  que sólo utilizan arcos con probabilidad mayor a cero y tiene largo infinito.

Dado  $n \in \mathbb{N}$ , sea  $V_b^{(n)}$  una variable aleatoria tal que  $V_b^{(n)} = 1$  si el estado en la caminata es  $b$  después de recorrer  $n$  arcos en  $G_P$ , y  $V_b^{(n)} = 0$  en caso contrario.

Tenemos que:

$$V_b = \sum_{n \in \mathbb{N}} V_b^{(n)}$$



# Una segunda caracterización de los estado recurrentes

Concluimos que:

$$\mathbf{E}[V_b] = \sum_{n \in \mathbb{N}} \mathbf{E}[V_b^{(n)}]$$

# Una segunda caracterización de los estado recurrentes

Concluimos que:

$$\mathbf{E}[V_b] = \sum_{n \in \mathbb{N}} \mathbf{E}[V_b^{(n)}]$$

Así, dado que  $V_b^{(n)} \sim \mathbf{Ber}(\mathbf{Pr}(X_n = b \mid X_0 = b))$ , concluimos que:

$$\mathbf{E}[V_b] = \sum_{n \in \mathbb{N}} \mathbf{Pr}(X_n = b \mid X_0 = b)$$

# Una segunda caracterización de los estado recurrentes

Concluimos que:

$$\mathbf{E}[V_b] = \sum_{n \in \mathbb{N}} \mathbf{E}[V_b^{(n)}]$$

Así, dado que  $V_b^{(n)} \sim \mathbf{Ber}(\mathbf{Pr}(X_n = b \mid X_0 = b))$ , concluimos que:

$$\mathbf{E}[V_b] = \sum_{n \in \mathbb{N}} \mathbf{Pr}(X_n = b \mid X_0 = b)$$

## Corolario

*b es recurrente si y sólo si*

$$\sum_{n \in \mathbb{N}} \mathbf{Pr}(X_n = b \mid X_0 = b) = \infty$$

# Una tercera propiedad fundamental: estados recurrentes positivos

## Definition

Un estado  $b$  en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$  es recurrente positivo si  $b$  es recurrente y  $\mathbf{E}[T_b] \in \mathbb{R}$

# Una tercera propiedad fundamental: estados recurrentes positivos

## Definition


Un estado  $b$  en una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$  es recurrente positivo si  $b$  es recurrente y  $\mathbf{E}[T_b] \in \mathbb{R}$

## Ejercicio

De una cadena de Markov  $\{X_t\}_{t \in \mathbb{N}}$  con conjunto de estados  $\Omega$  y un estado  $b \in \Omega$  tal que  $b$  es recurrente pero no recurrente positivo.


# Una solución para el ejercicio

Considere la siguiente cadena de Markov con conjunto de estados  $\Omega = \mathbb{N}$ :



# Una solución para el ejercicio

Considere la siguiente cadena de Markov con conjunto de estados  $\Omega = \mathbb{N}$ :



Tenemos que 0 es un estado recurrente pero no recurrente positivo.

# Existencia y unicidad de la distribución estacionaria: el caso general

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov irreducible, aperiódica y **donde cada estado es recurrente positivo**

- ▶ Y sea  $\vec{\pi} \in [0, 1]^{|\Omega|}$  un vector tal que  $\vec{\pi}[a] = \lambda_a$  para cada  $a \in \Omega$ , donde  $\Omega$  es el conjunto de estados de  $\{X_t\}_{t \in \mathbb{N}}$ 
  - ▶ Nótese que  $\Omega$  puede ser un conjunto infinito enumerable
  - ▶  $\lambda_a = \lim_{n \rightarrow \infty} \mathbf{Pr}(X_n = a \mid X_0 = b)$ , vale decir,  $\lambda_a$  es definido como en el caso finito considerando un estado arbitrario  $b \in \Omega$  (todos los puntos de partida dan el mismo resultado)



# Existencia y unicidad de la distribución estacionaria: el caso general

Sea  $\{X_t\}_{t \in \mathbb{N}}$  una cadena de Markov irreducible, aperiódica y **donde cada estado es recurrente positivo**

- ▶ Y sea  $\vec{\pi} \in [0, 1]^{|\Omega|}$  un vector tal que  $\vec{\pi}[a] = \lambda_a$  para cada  $a \in \Omega$ , donde  $\Omega$  es el conjunto de estados de  $\{X_t\}_{t \in \mathbb{N}}$ 
  - ▶ Nótese que  $\Omega$  puede ser un conjunto infinito enumerable
  - ▶  $\lambda_a = \lim_{n \rightarrow \infty} \mathbf{Pr}(X_n = a \mid X_0 = b)$ , vale decir,  $\lambda_a$  es definido como en el caso finito considerando un estado arbitrario  $b \in \Omega$  (todos los puntos de partida dan el mismo resultado)

## Teorema

*$\vec{\pi}$  es la única distribución estacionaria para  $\{X_t\}_{t \in \mathbb{N}}$*

# Un recordatorio de Álgebra Lineal

Estudiar las cadenas de Markov a través de sus matrices de transición nos puede ayudar a entender mejor su comportamiento.

# Un recordatorio de Álgebra Lineal

Estudiar las cadenas de Markov a través de sus matrices de transición nos puede ayudar a entender mejor su comportamiento. Para esto, vamos a recordar unos conceptos de Álgebra Lineal.

# Un recordatorio de Álgebra Lineal

Estudiar las cadenas de Markov a través de sus matrices de transición nos puede ayudar a entender mejor su comportamiento. Para esto, vamos a recordar unos conceptos de Álgebra Lineal.

## Definición

Sea  $A$  una matriz cuadrada. Un **vector propio** de  $A$  es un vector (no nulo)  $\bar{x}$  tal que  $A\bar{x} = \lambda\bar{x}$ , donde  $\lambda \in \mathbb{R}$ . Este  $\lambda$  a su vez es un **valor propio** de  $M$ .

# Un recordatorio de Álgebra Lineal

Estudiar las cadenas de Markov a través de sus matrices de transición nos puede ayudar a entender mejor su comportamiento. Para esto, vamos a recordar unos conceptos de Álgebra Lineal.

## Definición

Sea  $A$  una matriz cuadrada. Un **vector propio** de  $A$  es un vector (no nulo)  $\bar{x}$  tal que  $A\bar{x} = \lambda\bar{x}$ , donde  $\lambda \in \mathbb{R}$ . Este  $\lambda$  a su vez es un **valor propio** de  $M$ .

Naturalmente, si  $\bar{x}$  es vector propio de  $M$ , para cualquier valor  $a \in \mathbb{R}$  se tiene que  $a \cdot \bar{x}$  también lo es.

## Definición

El **polinomio característico** de una matriz cuadrada  $A$  es el determinante de  $A - \lambda I$ , donde  $I$  es la matriz identidad.

## Definición

El **polinomio característico** de una matriz cuadrada  $A$  es el determinante de  $A - \lambda I$ , donde  $I$  es la matriz identidad.

Notemos que  $A\vec{x} = \lambda\vec{x}$  equivale a que  $(A - \lambda I)\vec{x}$  sea el vector 0 para un vector no nulo  $\vec{x}$ . Es decir,  $A - \lambda I$  es no invertible, y su determinante es 0.

## Definición

El **polinomio característico** de una matriz cuadrada  $A$  es el determinante de  $A - \lambda I$ , donde  $I$  es la matriz identidad.

Notemos que  $A\vec{x} = \lambda\vec{x}$  equivale a que  $(A - \lambda I)\vec{x}$  sea el vector 0 para un vector no nulo  $\vec{x}$ . Es decir,  $A - \lambda I$  es no invertible, y su determinante es 0.

Por lo tanto,  $\lambda$  es raíz del polinomio característico de  $A$  si y sólo si es valor propio.



## Corolario

*Una matriz  $A$  de tamaño  $n \times n$  tiene a lo más  $n$  valores propios. Además, son los mismos que los de su matriz transpuesta  $A^T$ .*

## Corolario

*Una matriz  $A$  de tamaño  $n \times n$  tiene a lo más  $n$  valores propios. Además, son los mismos que los de su matriz transpuesta  $A^T$ .*

El grado de  $\lambda$  en el determinante de  $A - \lambda I$  es a lo más  $n$ , así que la primera parte se cumple por el teorema fundamental del álgebra.

## Corolario

*Una matriz  $A$  de tamaño  $n \times n$  tiene a lo más  $n$  valores propios. Además, son los mismos que los de su matriz transpuesta  $A^T$ .*

El grado de  $\lambda$  en el determinante de  $A - \lambda I$  es a lo más  $n$ , así que la primera parte se cumple por el teorema fundamental del álgebra.

Para la segunda parte hay que recordar el determinante es simétrico respecto a filas y columnas, por lo que  $\det(A) = \det(A^T)$ . Luego,  $\det(A - \lambda I) = \det(A^T - \lambda I)$ , y sus raíces son las mismas.

# Valores propios de una cadena de Markov

## Teorema

*Considere una cadena de Markov **arbitraria** con una matriz de transición  $P$ . Se tiene que 1 es valor propio de  $P$ .*

# Valores propios de una cadena de Markov

## Teorema

*Considere una cadena de Markov **arbitraria** con una matriz de transición  $P$ . Se tiene que 1 es valor propio de  $P$ .*

**Demostración.** Tenemos que las columnas de  $P$  suman 1, y por lo tanto las filas de  $P^T$  también.

# Valores propios de una cadena de Markov

## Teorema

Considere una cadena de Markov **arbitraria** con una matriz de transición  $P$ . Se tiene que 1 es valor propio de  $P$ .

**Demostración.** Tenemos que las columnas de  $P$  suman 1, y por lo tanto las filas de  $P^T$  también.

Considere el siguiente vector:

$$\vec{x} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

Se tiene que  $\vec{x}$  es un vector propio de  $P^T$  con valor propio 1. Luego 1 es valor propio de  $P$ .

# Valores propios de una cadena de Markov

Si una cadena de Markov tiene una distribución estacionaria  $\vec{\pi}$  entonces cumple con  $P\vec{\pi} = 1 \cdot \pi$ . Es decir, tiene como valor propio 1.

# Valores propios de una cadena de Markov

Si una cadena de Markov tiene una distribución estacionaria  $\vec{\pi}$  entonces cumple con  $P\vec{\pi} = 1 \cdot \pi$ . Es decir, tiene como valor propio 1.

Sin embargo, que una matriz tenga valor propio 1 aún no nos dice que su vector propio sea una distribución de probabilidades.



# Valores propios de una cadena de Markov

Si una cadena de Markov tiene una distribución estacionaria  $\vec{\pi}$  entonces cumple con  $P\vec{\pi} = 1 \cdot \pi$ . Es decir, tiene como valor propio 1.

Sin embargo, que una matriz tenga valor propio 1 aún no nos dice que su vector propio sea una distribución de probabilidades. Podría tener componentes negativas.

# Valores propios de una cadena de Markov

Vamos a usar una herramienta clásica del Álgebra lineal

# Valores propios de una cadena de Markov

Vamos a usar una herramienta clásica del Álgebra lineal

## Teorema (Perron-Frobenius)

*Sea  $A$  una matriz finita sin componentes negativas. Existe un vector propio de  $A$  cuyas componentes son todas positivas.*

# Valores propios de una cadena de Markov

Vamos a usar una herramienta clásica del Álgebra lineal

## Teorema (Perron-Frobenius)

*Sea  $A$  una matriz finita sin componentes negativas. Existe un vector propio de  $A$  cuyas componentes son todas positivas.*

## Corolario

*Toda cadena de Markov finita tiene una distribución estacionaria.*

**Demostración.** Sea  $P$  su matriz de transición, y sea  $\vec{x}$  un vector propio positivo con valor propio  $\lambda$ .

**Demostración.** Sea  $P$  su matriz de transición, y sea  $\vec{x}$  un vector propio positivo con valor propio  $\lambda$ .

Normalizamos este vector de tal manera que la suma de sus componentes es 1. Sigue siendo vector propio para  $\lambda$ .

**Demostración.** Sea  $P$  su matriz de transición, y sea  $\vec{x}$  un vector propio positivo con valor propio  $\lambda$ .

Normalizamos este vector de tal manera que la suma de sus componentes es 1. Sigue siendo vector propio para  $\lambda$ .

Luego tenemos que  $P\vec{x} = \lambda\vec{x}$ . Como la suma de todas las columnas de  $P$  es 1, entonces la suma de los componentes de  $\lambda\vec{x}$  también es 1.

# Valores propios de una cadena de Markov

**Demostración.** Sea  $P$  su matriz de transición, y sea  $\vec{x}$  un vector propio positivo con valor propio  $\lambda$ .

Normalizamos este vector de tal manera que la suma de sus componentes es 1. Sigue siendo vector propio para  $\lambda$ .

Luego tenemos que  $P\vec{x} = \lambda\vec{x}$ . Como la suma de todas las columnas de  $P$  es 1, entonces la suma de los componentes de  $\lambda\vec{x}$  también es 1.

Finalmente, como  $\sum_i x_i = \sum_i \lambda x_i$ , entonces  $\lambda = 1$ , por lo que  $\vec{x}$  es una distribución estacionaria. □